Report Data Analytics

Leonardo Vorabbi – Informatica LM – 0001186597
Carlotta Nunziati – Informatica LM – 0001181860

Anno Accademico 2025/2026

1 Introduzione

Il presente progetto ha come obiettivo la predizione del grado di rischio associato a un prestito finanziario sulla base delle caratteristiche del richiedente e delle condizioni del finanziamento. Il problema affrontato è un task di classificazione supervisionata, in cui la variabile target è rappresentata da un grado di rischio ordinato che assume valori da A, indicante il rischio più basso, a G, corrispondente al rischio più elevato. L'obiettivo del modello è assegnare a ciascuna richiesta di prestito una corretta categoria di rischio creditizio.

Il lavoro è stato sviluppato seguendo una pipeline completa di Data Analytics, comprendente le fasi di Data Acquisition, Data Visualization, Data Preprocessing, Modeling e Performance Evaluation, ciascuna progettata in funzione delle specifiche esigenze del task di classificazione del rischio di credito.

Nella fase di modellazione sono state adottate diverse tecniche di machine learning supervisionato, organizzate secondo tre livelli di complessità. Il primo livello include modelli tradizionali non deep, quali Random Forest, Support Vector Machines e K-Nearest Neighbors. Il secondo livello prevede l'utilizzo di reti neurali con architettura Feed-Forward. Infine, il terzo livello comprende modelli deep specifici per dati tabulari, come TabNet e TabTransformer.

Nel report vengono illustrate in dettaglio le principali fasi del progetto, le scelte metodologiche adottate e i risultati ottenuti. I modelli sviluppati saranno infine utilizzati per l'inferenza su un set di test non reso disponibile agli studenti, secondo le modalità definite dal corso.

2 Metodologia

2.1 Data Acquisition

La fase di Data Acquisition consiste nell'acquisizione e nel caricamento del dataset necessario allo svolgimento del progetto, garantendo al contempo la corretta organizzazione dei dati e la riproducibilità del processo. In questo caso si tratta di una Flat Data Acquisition, in quanto i dati erano già disponibili. In questa fase, il dataset train.csv è stato scaricato e importato all'interno del notebook utilizzando la libreria Pandas, ampiamente impiegata per la gestione e l'analisi di dati tabulari in ambiente Python.

Il dataset risultante è composto da 148.301 righe e 145 colonne, ciascuna delle quali rappresenta una specifica caratteristica associata alle richieste di prestito. I dati utilizzati contengono informazioni storiche relative a richieste di finanziamento presentate da clienti su una grande piattaforma online. Ogni istanza del dataset rappresenta una singola richiesta di prestito ed è descritta attraverso un insieme di indicatori finanziari, attributi demografici e metriche legate al credito, che caratterizzano sia il profilo del richiedente sia le condizioni del prestito stesso.

2.2 Data Visualization

La fase di Data Visualization ha l'obiettivo di esplorare il dataset in modo approfondito, comprendendone la struttura, la qualità dei dati e le principali relazioni tra le variabili, al fine di guidare in modo consapevole le successive fasi di preprocessing e modellazione. Attraverso l'uso di tecniche di visualizzazione e analisi descrittiva è possibile individuare problematiche quali valori mancanti, sbilanciamenti, outlier e correlazioni significative con la variabile target.

L'analisi preliminare non ha evidenziato la presenza di record duplicati, indicando una buona qualità strutturale dei dati dal punto di vista dell'unicità delle osservazioni.

È stata condotta un'analisi approfondita dei valori mancanti, calcolando la percentuale di dati assenti per ciascuna colonna. I risultati mostrano che numerose feature presentano percentuali di valori mancanti molto elevate, con percentuali superiori al 90% in molte colonne. Questa analisi ha evidenziato la necessità di operare una selezione delle feature e strategie di gestione dei missing value nella fase di preprocessing.

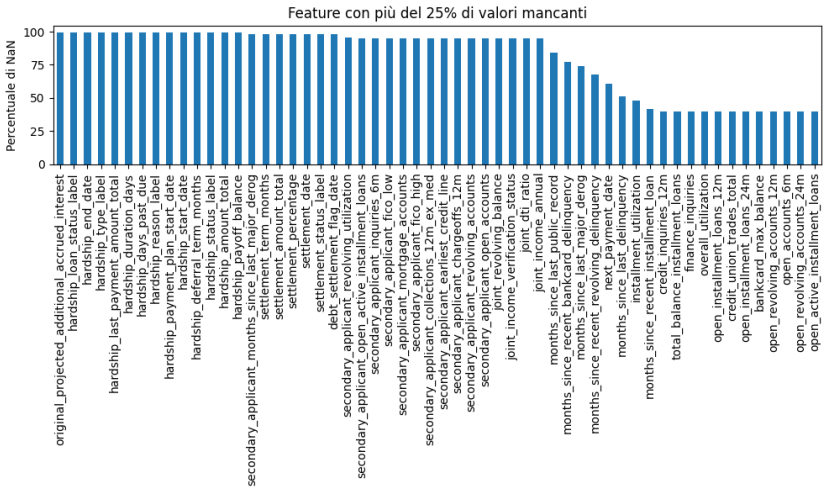

Figure 1: Distribuzione dei valori mancanti per le principali feature del dataset.

Successivamente, è stata analizzata la tipologia delle variabili, osservando una combinazione di feature numeriche e categoriali. Le variabili categoriali sono state esplorate in termini di valori unici, consentendo di comprendere la cardinalità delle categorie e la natura delle informazioni contenute.

```
Feature: loan_contract_term_months
Valori: [' 36 months' ' 60 months']
-----------------------
Feature: borrower_profile_employment_length
Valori: ['10+ years' '2 years' '8 years' '1 year' '3 years' '6 years' '7 years'
 '9 years' '< 1 year' '5 years' '4 years']
-----------------------
Feature: borrower_housing_ownership_status
Valori: ['rent' 'mortgage' 'own' 'any' 'other' 'none']
-----------------------
Feature: borrower_income_verification_status
Valori: ['source verified' 'not verified' 'verified']
```

Figure 2: Esempio di valori delle feature categoriali del dataset.

A fini esclusivamente esplorativi, alcune variabili categoriali sono state codificate in forma numerica (binaria, ordinale o nominale) per permettere analisi statistiche e visualizzazioni più efficaci, senza influenzare direttamente la fase di modeling.

È stata inoltre effettuata una ricerca sistematica degli outlier sulle variabili numeriche, utilizzando il metodo dell'Interquartile Range (IQR).

L'analisi descrittiva delle variabili evidenzia una marcata eterogeneità nelle distribuzioni dei dati, con una forte presenza di asimmetria e valori estremi. Numerose variabili presentano una mediana pari a zero, in-

dicando che la maggior parte delle osservazioni assume valori nulli, come *delinquency_amount*, mentre pochi casi isolati generano outlier di elevata entità, come nel caso di *total_collection_amount* e *credit_public_records*. Inoltre, variabili come
borrower_income_annual mostrano distribuzioni caratterizzate da code lunghe, con valori massimi estremamente elevati rispetto ai valori centrali. Nel complesso, queste evidenze confermano la presenza di eventi rari ma altamente impattanti e sottolineano la necessità di adottare tecniche di preprocessing robuste nella fase successiva di modellazione.

index	median	max	outlier_count	severity_ratio
total_collection_amount	0.0	380757.0	22002	380757.0
delinquency_amount	0.0	65900.77878743561	493	65900.77878743561
outstanding_principal_balance	0.0	46106.62885807047	14475	46106.62885807047
outstanding_principal_investor_side	0.0	43855.31853307119	14504	43855.31853307119
recoveries_cash	0.0	32321.34	14536	32321.34
collection_recovery_fee	0.0	5459.4	13923	5459.4
total_received_late_fees	0.0	983.43	6357	983.43
total_revolving_high_credit_limit	25000.0	9999999.0	8406	399.98396064157436
revolving_balance	11401.0	2560703.0	8816	224.58366953166112
borrower_income_annual	65000.0	9300086.0	7102	143.0760449839233
bankcard_open_to_buy	5035.0	454843.0	12182	90.31830818109611
total_high_credit_limit	112049.0	9999999.0	5021	89.24586345381526
total_current_balance	78221.0	5752177.0	5083	73.53656260387103
last_payment	618.0	43571.73631726761	21137	70.3905271684452 6
total_balance_ex_mortgage	38484.0	2688920.0	8547	69.86929972716644
average_current_balance	7274.0	479348.0	7626	65.88975945017182
credit_public_records	0.0	63.0	23601	63.0
tax_liens_total	0.0	63.0	4304	63.0
borrower_dti_ratio	18.16	1121.4841256221612	1416	58.53257440616707
credit_union_trades_total	0.0	48.0	6550	48.0

Figure 3: Esempio di analisi degli outlier nelle variabili numeriche del dataset utilizzando il metodo IQR.

Le visualizzazioni tramite boxplot e density plot hanno inoltre mostrato una chiara variazione delle distribuzioni di alcune feature al variare del grado di rischio. A titolo esemplificativo, nel report sono riportate alcune distribuzioni rappresentative emerse dall'analisi. In particolare, vengono mostrati esempi di variabili con mediana nulla e outlier estremi (come *delinquency_amount*), variabili economiche caratterizzate da code lunghe (come *borrower_income_annual*) e variabili che presentano un'elevata concentrazione di osservazioni anomale (come *credit_public_records*).

I boxplot e i density plot evidenziano chiaramente la presenza di valori anomali e distribuzioni non gaussiane, confermando la necessità di adottare tecniche di preprocessing robuste nella fase successiva.

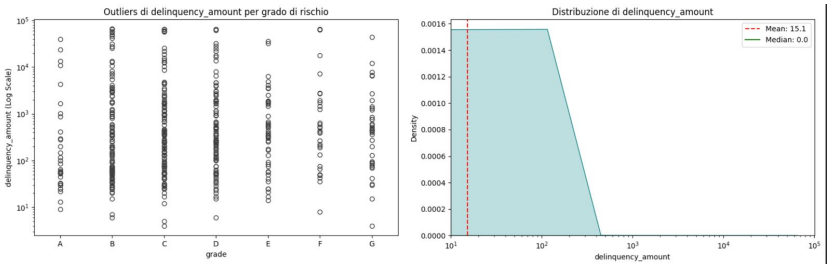

Figure 4: Distribuzione di *delinquency_amount* per grado di rischio. La variabile mostra un evento raro: nonostante possa sembrare che siano presenti numerosi outlier, la mediana è pari a 0, il che indica che la maggior parte dei valori è nulla.

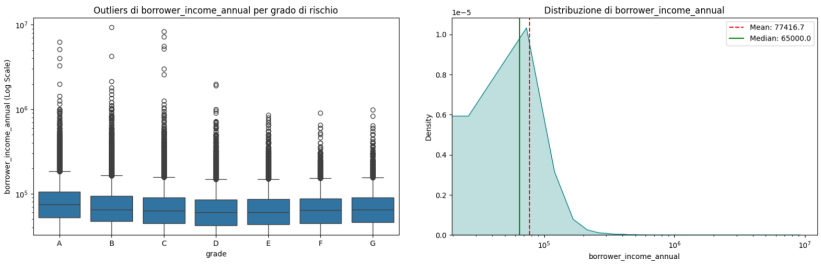

Figure 5: Distribuzione del reddito annuale del richiedente (*borrower_income_annual*) per grado di rischio. La variabile mostra una marcata asimmetria a destra e code lunghe, con valori estremi che differiscono significativamente dalla mediana. Tali valori estremi sono attribuibili a una ristretta quota di individui con redditi molto elevati.

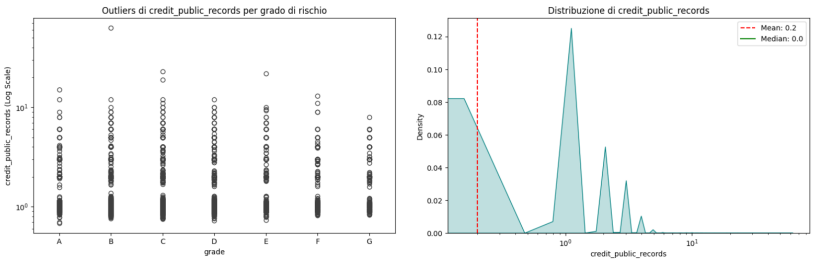

Figure 6: Distribuzione del numero di segnalazioni pubbliche (*credit_public_records*) per grado di rischio. La variabile è fortemente asimmetrica e caratterizzata da eventi rari ma rilevanti, riflettendo un'elevata eterogeneità nei dati.

È stata inoltre svolta una cross analysis tra alcune variabili chiave del

profilo creditizio, con l'obiettivo di esplorare le principali relazioni bivariate e il loro legame con il grado di rischio. In particolare, sono state analizzate le interazioni tra punteggio FICO e rapporto debito/reddito (DTI), tra reddito annuale e utilizzo del credito revolving, e tra punteggio FICO e tasso di interesse. I risultati mostrano che i prestiti a basso rischio tendono a concentrarsi in corrispondenza di punteggi FICO più elevati e valori di DTI contenuti, mentre i gradi di rischio più alti presentano una maggiore dispersione e livelli di indebitamento più elevati. Dal grafico osservato tra reddito e utilizzo del credito , non sembra emergere una relazione chiara tra rischio e stress finanziario. I punti appaiono distribuiti in maniera piuttosto dispersa, formando una "nuvola" senza un andamento definito, il che suggerisce l'assenza di un legame diretto tra le due variabili. Infine, il confronto tra FICO e tasso di interesse conferma la coerenza economica del dataset, con tassi mediamente più alti associati a punteggi FICO più bassi e a gradi di rischio maggiori.

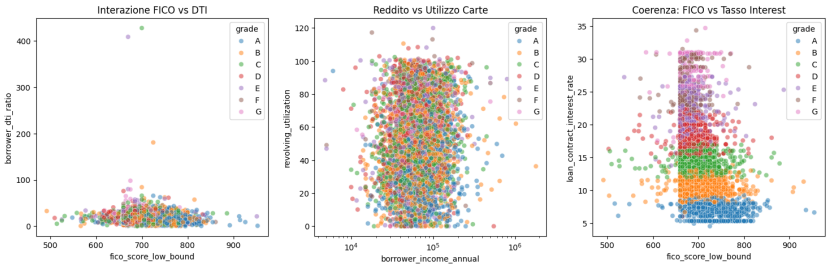

Figure 7: Analisi delle relazioni tra variabili finanziarie e grado di rischio. Da sinistra a destra: Interazione tra FICO score e rapporto debito/reddito (DTI), reddito annuale vs utilizzo delle carte di credito, e FICO score vs tasso di interesse del prestito. I punti sono colorati in base al grado di rischio (grade).

L'analisi della distribuzione della variabile target ha confermato uno sbilanciamento delle classi, con una maggiore concentrazione nei gradi di rischio intermedi (A, B e C) e una presenza ridotta delle classi più rischiose (F e G).

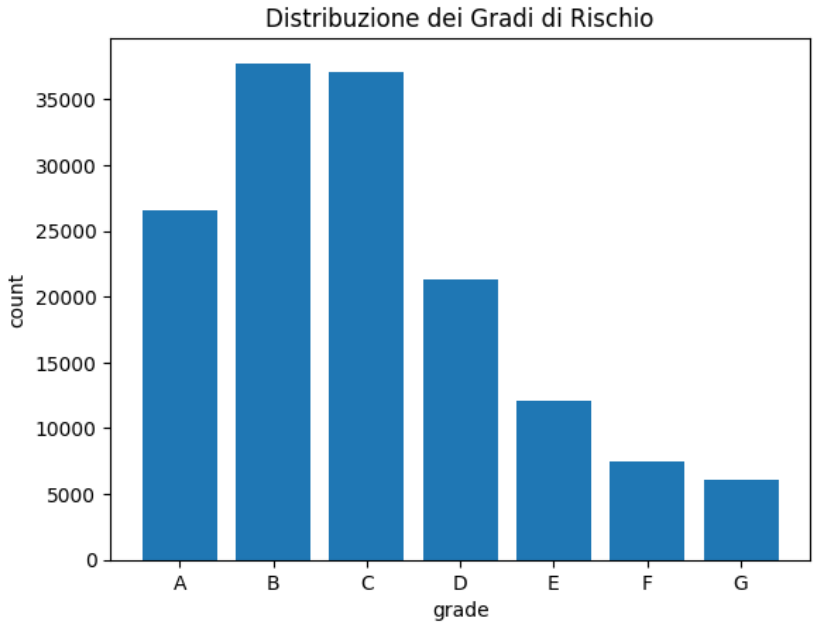

Figure 8: Distribuzione dei gradi di rischio.

Infine, è stata condotta un'analisi delle correlazioni tra le feature numeriche e la variabile target, individuando le variabili maggiormente associate al grado di rischio. Le heatmap di correlazione hanno evidenziato l'importanza di indicatori creditizi e finanziari, fornendo indicazioni utili per la selezione delle feature.

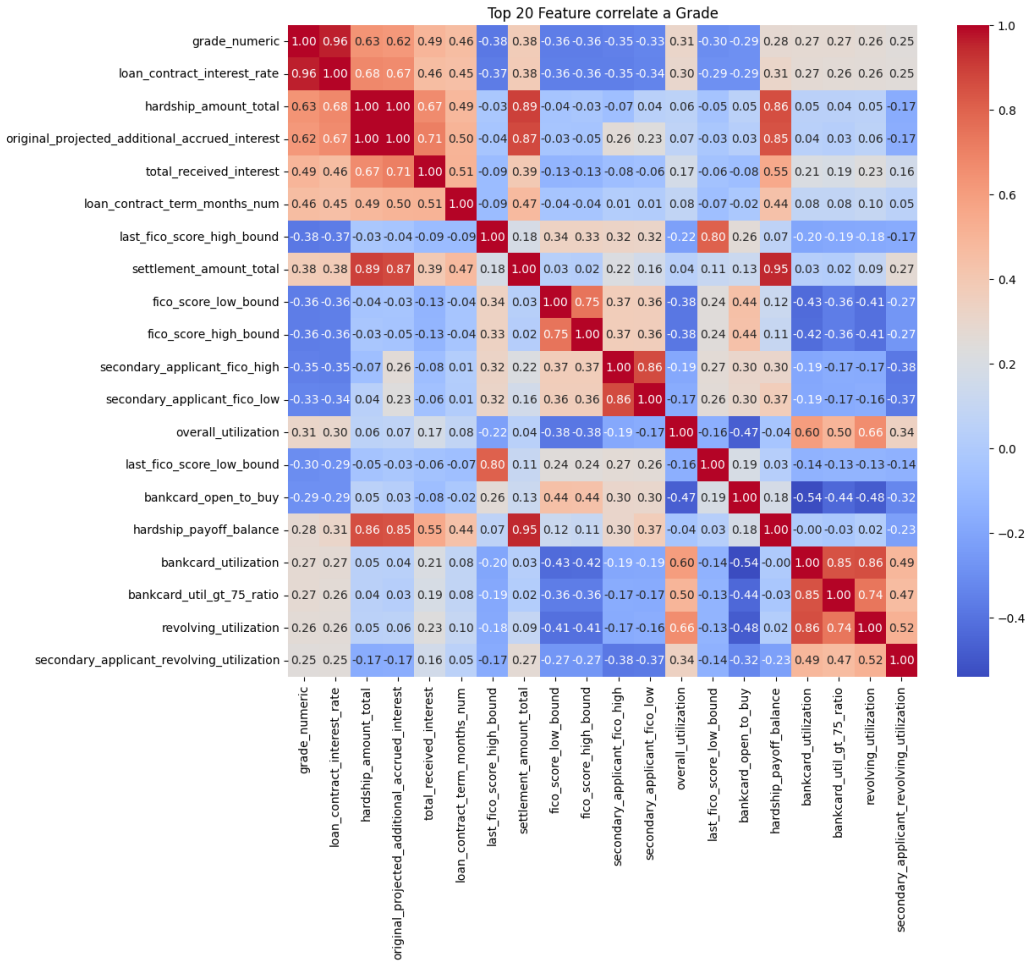

Figure 9: Heatmap delle 20 feature numeriche più correlate alla variabile target.

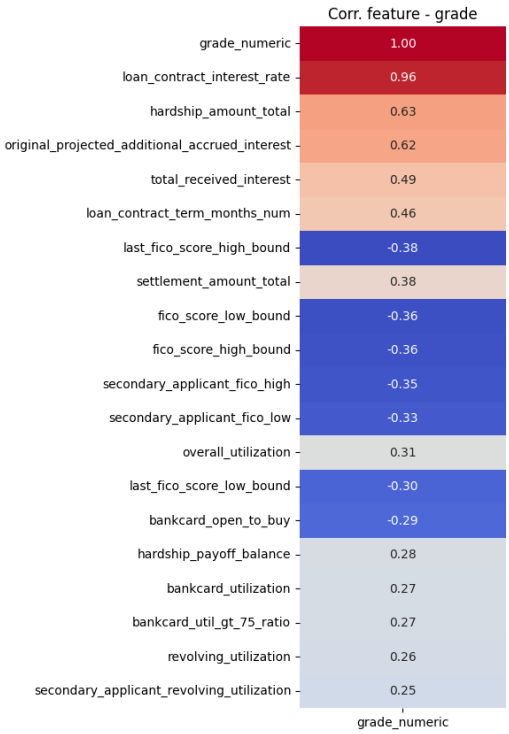

Figure 10: 20 feature numeriche con maggiore correlazione con la variabile target.

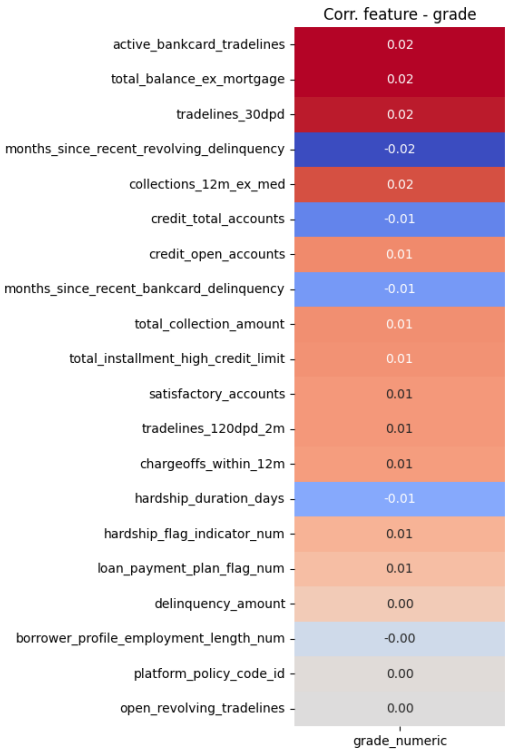

Figure 11: 20 feature numeriche con minor correlazione con la variabile target.

Nel complesso, la fase di Data Visualization ha permesso di acquisire una comprensione approfondita del dataset, individuando criticità e pattern rilevanti che hanno guidato in modo diretto le scelte effettuate nelle successive fasi di preprocessing e modellazione.

2.3 Data Pre-processing

Il preprocessing dei dati ha rappresentato una fase fondamentale del progetto, in quanto ha permesso di trasformare il dataset grezzo in una rappresentazione coerente, informativa e adatta all'addestramento di modelli di classificazione supervisionata. Il dataset originale è stato inizialmente suddiviso in training set, validation set e test set secondo una proporzione 80–10–10, utilizzando un seed fisso per garantire la riproducibilità degli esperimenti e una corretta valutazione delle prestazioni del modello su dati non visti.

Successivamente è stata condotta un'analisi dei valori mancanti che ha portato all'eliminazione delle feature con oltre il 25% di valori nulli, poiché considerate poco affidabili e potenzialmente dannose per la stabilità del mod-

ello. A questa fase è seguita la rimozione manuale di alcune variabili ritenute poco significative o non utilizzabili in uno scenario reale di previsione del rischio creditizio, come le feature testuali libere o quelle legate a eventi successivi all'erogazione del prestito, al fine di evitare fenomeni di data leakage.

I valori mancanti nelle feature rimanenti sono stati gestiti tramite imputazione, utilizzando la mediana per le variabili numeriche, scelta per la sua robustezza rispetto agli outlier, e la moda per le variabili categoriche, così da preservarne la distribuzione originale. Le variabili temporali sono state trasformate per renderle utilizzabili dai modelli di machine learning, convertendo le date in formato datetime, scomponendole in anno e mese e introducendo una nuova feature che rappresenta l'anzianità della storia creditizia del richiedente in mesi, informazione rilevante per la valutazione del rischio. La durata dell'impiego è stata inoltre convertita da formato testuale a numerico tramite una mappatura ordinata.

Per limitare l'influenza dei valori estremi, è stata applicata una procedura di clipping degli outlier basata sull'Interquartile Range per le feature numeriche, affiancata da regole specifiche per variabili percentuali e per gli score FICO, riportati entro intervalli realistici. Sono state poi eliminate le feature a varianza nulla, in quanto prive di capacità discriminante.

La variabile target, rappresentante il grado di rischio creditizio, è stata codificata tramite una mappatura ordinata, mentre le feature categoriche sono state trasformate mediante una strategia di encoding configurabile, finalizzata a bilanciare capacità rappresentativa e complessità del modello. In particolare, quando il parametro `ONLY_LABEL_ENCODING` è impostato a `False`, viene adottata una strategia ibrida che prevede l'applicazione del One-Hot Encoding alle variabili a bassa cardinalità e del Label Encoding a quelle ad alta cardinalità, così da limitare l'aumento della dimensionalità del dataset mantenendo al contempo un'adeguata espressività delle categorie. Quando invece `ONLY_LABEL_ENCODING` è impostato a `True`, tutte le feature categoriche vengono codificate esclusivamente tramite Label Encoding. La distinzione tra le diverse strategie di codifica delle feature è stata introdotta inizialmente con finalità esclusivamente sperimentali, al fine di analizzare il loro impatto sulle prestazioni del modello TabTransformer. In particolare, sono state confrontate configurazioni basate su differenti modalità di encoding delle variabili categoriali. Sulla base dei risultati empirici ottenuti, è emerso che l'impostazione con `ONLY_LABEL_ENCODING = False` garantisce le migliori prestazioni complessive per il TabTransformer.

Per ridurre la ridondanza informativa e i problemi di multicollinearità, sono state eliminate le feature altamente correlate, seguite da un'ulteriore selezione basata sulla Mutual Information, che ha consentito di rimuovere le variabili con scarso potere predittivo rispetto alla variabile target.

Il dataset finale ottenuto risulta quindi più compatto, informativo e adatto all'apprendimento. Considerata la forte asimmetria nella distribuzione delle classi di rischio, è stato infine applicato un bilanciamento del training set tramite Random Under-Sampling, ottenendo una distribuzione uniforme delle classi.

Tutti gli oggetti e i parametri necessari al preprocessing sono stati salvati e riutilizzati per applicare in modo coerente le stesse trasformazioni ai validation e test set, garantendo l'assenza di data leakage e la comparabilità dei risultati sperimentali.

3 Modellazione

3.1 Tecniche di ML supervised tradizionali non deep

Il problema di predizione del rischio creditizio è stato inizialmente affrontato utilizzando diverse tecniche di Machine Learning classico, con l'obiettivo di confrontarne le prestazioni e individuare il modello più adatto al task di classificazione multiclasse ordinata. I modelli selezionati includono K-Nearest Neighbors, Random Forest e Support Vector Machine, rappresentativi di approcci basati rispettivamente su distanza, ensemble di alberi decisionali e margine massimo. La selezione degli iperparametri e il confronto tra le diverse configurazioni sono stati effettuati mediante una GridSearch con cross-validation, che consente una stima più robusta delle prestazioni di generalizzazione dei modelli, riducendo la dipendenza da una singola suddivisione dei dati. La procedura di cross-validation integra implicitamente una fase di validazione all'interno di ciascun fold, pertanto, non è stato necessario definire un validation set esplicito. Di conseguenza, il training set e il validation set inizialmente previsti, entrambi bilanciati tramite under-sampling, sono stati combinati in un unico insieme di addestramento, sul quale è stata applicata la cross-validation. Il test set è stato invece mantenuto completamente separato ed è stato utilizzato esclusivamente per la valutazione finale del modello selezionato, al fine di garantire una stima imparziale delle prestazioni su dati non visti.

Nel complesso, il confronto tra i modelli evidenzia come le tecniche di Machine Learning classico siano in grado di fornire prestazioni solide nel contesto della predizione del rischio creditizio, con la Random Forest che emerge come il modello più performante e robusto. I risultati ottenuti confermano l'importanza di una fase di preprocessing accurata e di una selezione oculata delle feature, che consentono anche a modelli tradizionali di raggiungere livelli di accuratezza elevati e una buona capacità di generalizzazione.

3.1.1 KNN

Il primo approccio considerato è stato il modello K-Nearest Neighbors (KNN), basato sull'ipotesi che osservazioni simili nello spazio delle feature tendano ad appartenere alla stessa classe. Poiché KNN è particolarmente sensibile sia alla scala delle variabili sia all'elevata dimensionalità dei dati, il modello è stato inserito all'interno di una pipeline comprendente una fase di standardizzazione (StandardScaler) delle feature seguita da una riduzione dimensionale tramite Linear Discriminant Analysis (LDA). L'utilizzo della LDA consente di proiettare i dati in uno spazio a dimensionalità ridotta massimizzando la separazione tra le classi, migliorando la discriminabilità dei campioni e l'efficacia del criterio di distanza su cui si basa il modello KNN. Il modello KNN adottato utilizza la distanza Manhattan (L1) per confrontare i punti nello spazio delle feature.

La selezione degli iperparametri è stata effettuata mediante Grid Search con cross-validation a cinque fold. In particolare, sono state valutate diverse configurazioni dei seguenti iperparametri:

- *n_components (LDA)*: controlla il numero di componenti discriminanti mantenute nella proiezione, influenzando il compromesso tra riduzione della dimensionalità e preservazione dell'informazione discriminativa tra le classi;
- *n_neighbors*: definisce il numero di vicini considerati nella fase di classificazione, regolando il bilanciamento tra sensibilità al rumore e capacità di generalizzazione del modello;
- *weights*: stabilisce la modalità con cui i vicini contribuiscono alla decisione finale, distinguendo tra una pesatura uniforme e una pesatura basata sulla distanza, che assegna maggiore importanza ai campioni più vicini al punto da classificare.

I valori ottimali degli iperparametri sono stati individuati massimizzando l'accuracy media sui fold di validazione. I parametri ottimali individuati sono stati:

- *n_components (LDA)* = 6;
- *n_neighbors* = 31;
- *weights* = distance.

Il modello finale è stato quindi utilizzato per effettuare le predizioni sul test set e per calcolare le metriche di performance, oltre alla matrice di confusione. Il modello selezionato ha mostrato buone prestazioni complessive, ottenendo un'accuracy pari a circa **0.83** sul test set.

Le metriche per classe mostrano:

- Precision e recall elevati per le classi a basso rischio, indicando una buona affidabilità nelle predizioni di soggetti meno rischiosi;
- Recall più basso per le classi di rischio elevato, segno di una maggiore difficoltà nell'identificare correttamente tali osservazioni;
- F1-score complessivamente bilanciato, ma penalizzato sulle classi meno rappresentate e più simili tra loro.

Nel complesso, il KNN fornisce prestazioni soddisfacenti, ma risulta limitato nella capacità di modellare confini complessi tra classi vicine.

Accuracy: 0.8275908569887398

	precision	recall	f1-score	support
0	0.91	0.94	0.92	2647
1	0.88	0.84	0.86	3789
2	0.86	0.84	0.85	3689
3	0.78	0.82	0.80	2156
4	0.70	0.72	0.71	1203
5	0.62	0.52	0.57	711
6	0.69	0.85	0.76	636
accuracy			0.83	14831
macro avg	0.78	0.79	0.78	14831
weighted avg	0.83	0.83	0.83	14831

Figure 12: Metriche di performance - KNN

La matrice di confusione del modello KNN mostra una buona capacità di classificazione per le classi di rischio più basse, che risultano correttamente identificate nella maggior parte dei casi. In particolare, la classe a rischio minimo presenta un'elevata concentrazione di predizioni corrette lungo la diagonale principale. Al contrario, si osserva una maggiore confusione tra le classi di rischio intermedio ed elevato. Gli errori sono prevalentemente localizzati tra classi adiacenti, indicando che il modello tende raramente a commettere errori "gravi", ma fatica a separare categorie vicine nello spazio

delle feature. Questo comportamento è coerente con la natura del modello, basato su distanze locali, e con la struttura ordinale del problema.

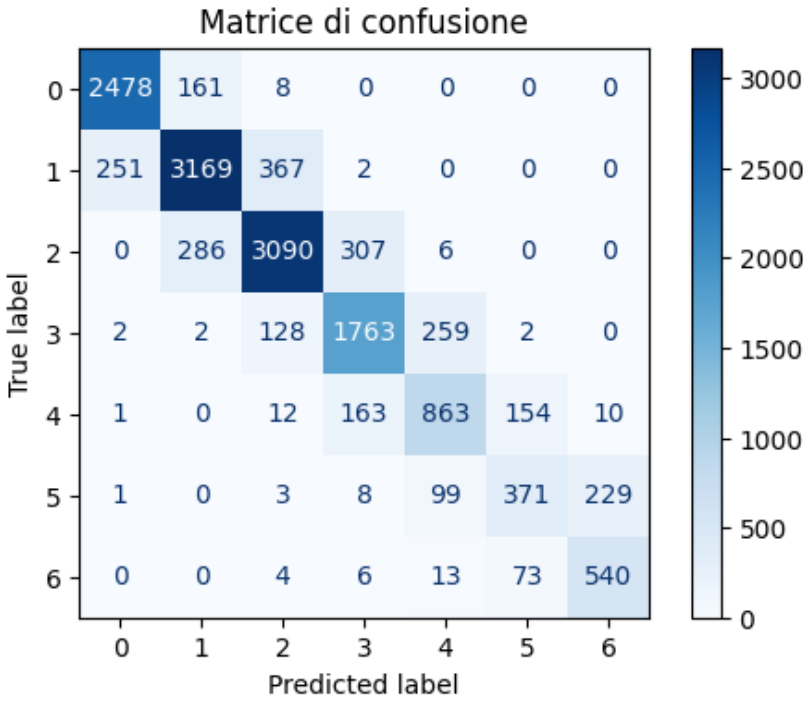

Figure 13: Matrice di confusione - KNN

3.1.2 Random Forest

Successivamente è stato utilizzato un modello Random Forest, basato su un insieme di alberi decisionali addestrati su sottoinsiemi casuali dei dati e delle feature. Questo approccio consente di catturare relazioni non lineari e interazioni complesse tra le variabili, risultando particolarmente adatto a dataset tabellari eterogenei come quello in esame. Anche in questo caso è stata utilizzata una pipeline comprendente una standardizzazione delle feature tramite StandardScaler, sebbene il modello non sia strettamente sensibile alla scala, al fine di mantenere coerenza con gli altri esperimenti.

La selezione degli iperparametri è stata effettuata mediante Grid Search con cross-validation a tre fold. In particolare, sono stati valutati diversi valori per i seguenti iperparametri:

- *n_estimators*: numero di alberi nella foresta, con un maggior numero di alberi che tende a migliorare la stabilità del modello aumentando però il costo computazionale;

- *max_depth*: profondità massima degli alberi, che regola il compromesso tra capacità di esprimere pattern complessi e rischio di overfitting;
- *min_samples_split*: numero minimo di campioni richiesti per suddividere un nodo, utile a evitare suddivisioni troppo specifiche che ridurrebbero la generalizzazione.

Diverse combinazioni di questi parametri sono state valutate durante la fase di cross-validation, selezionando la configurazione che massimizzava l'accuracy media sui fold.

I migliori iperparametri ottenuti sono stati:

- *n_estimators*: 300;
- *max_depth*: 20;
- *min_samples_split*: 10.

Il modello finale è stato quindi utilizzato per effettuare le predizioni sul test set e per calcolare le metriche di performance, oltre alla matrice di confusione. Il modello selezionato ha mostrato buone prestazioni complessive, ottenendo un'accuracy pari a circa **0.90** sul test set.

Le metriche mostrano:

- Precision elevata su tutte le classi, indicando un basso tasso di falsi positivi;
- Recall anch'esso elevato;
- F1-score elevato e bilanciato, che conferma la robustezza del modello anche in presenza di classi difficili.

```
Accuracy: 0.8992650529296743
              precision    recall  f1-score   support

           0       0.96      0.98      0.97      2647
           1       0.95      0.90      0.92      3789
           2       0.89      0.92      0.91      3689
           3       0.88      0.87      0.88      2156
           4       0.82      0.84      0.83      1203
           5       0.78      0.70      0.74       711
           6       0.77      0.89      0.82       636

    accuracy                           0.90     14831
   macro avg       0.86      0.87      0.87     14831
weighted avg       0.90      0.90      0.90     14831
```

Figure 14: Metriche di performance - Random Forest

Il modello Random Forest ha ottenuto le migliori prestazioni complessive tra i modelli tradizionali testati, con valori elevati di precision e recall su tutte le classi. Questo risultato conferma l'efficacia degli ensemble di alberi nell'individuare pattern complessi e gestire feature eterogenee senza richiedere forti assunzioni sulla distribuzione dei dati. Il modello, tuttavia, ha mostrato tempi di addestramento significativamente più elevati rispetto agli altri approcci considerati.

La matrice di confusione del modello Random Forest evidenzia una forte concentrazione dei valori lungo la diagonale principale, indicando una percentuale maggiore di classificazioni corrette per tutte le classi di rischio. Rispetto agli altri modelli, la confusione tra classi adiacenti è sensibilmente ridotta. Il modello dimostra una maggiore capacità di distinguere correttamente anche le classi di rischio più elevato, che risultano spesso fonte di errore per approcci più semplici.

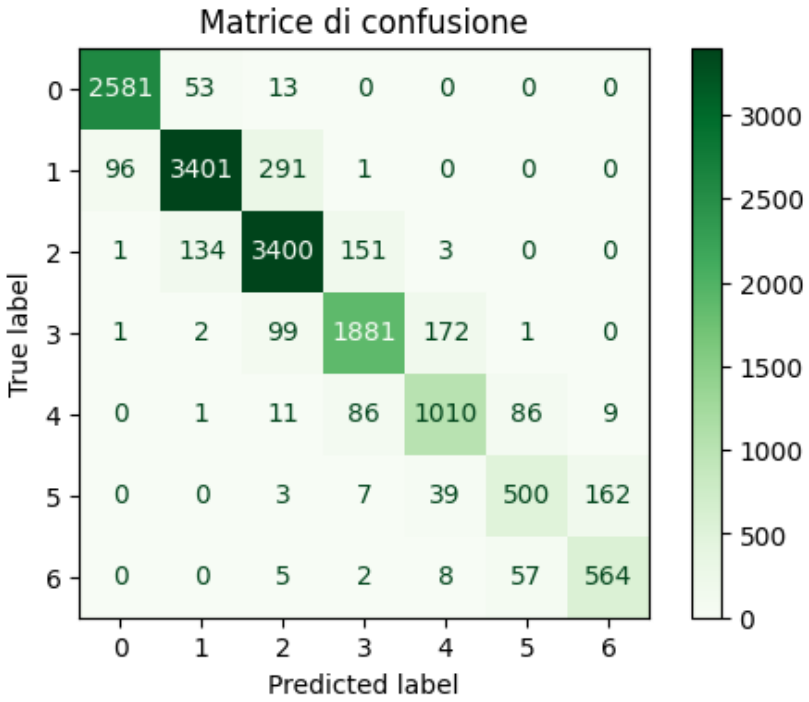

Figure 15: Matrice di confusione - Random Forest

3.1.3 SVM

Infine è stato valutato un modello Support Vector Machine (SVM), che mira a trovare l'iperpiano nello spazio delle feature che massimizza il margine tra le classi. Data l'elevata dimensionalità del dataset, anche in questo caso è stata applicata una riduzione dimensionale tramite Linear Discriminant Analysis (LDA) prima dell'addestramento, in modo da migliorare l'efficacia del modello e ridurre il rumore presente nelle feature.

La selezione degli iperparametri è stata effettuata mediante Grid Search con cross-validation a tre fold. In particolare, sono stati valutati diversi valori per i seguenti iperparametri:

- C: parametro di regolarizzazione che controlla la penalità degli errori; valori più alti riducono il margine di tolleranza agli errori, aumentando la complessità del modello;
- *kernel*: tipo di kernel utilizzato per proiettare i dati in uno spazio di feature adatto alla separazione lineare; sono stati testati kernel lineari e il kernel RBF, che consente di modellare confini non lineari;

- *gamma*: parametro specifico del kernel RBF che definisce l'influenza di ciascun punto di training sulla forma dell'iperpiano, controllando la complessità dei confini tra le classi;
- *n_components*: numero di componenti discriminanti mantenute nella LDA, influenzando il compromesso tra riduzione della dimensionalità e preservazione dell'informazione discriminativa.

Diverse combinazioni di questi parametri sono state valutate durante la fase di cross-validation, selezionando la configurazione che massimizzava l'accuracy media sui fold.

I migliori iperparametri ottenuti sono stati:

- *kernel*: RBF;
- *C*: 1;
- *gamma*: *auto*;
- *n_components (LDA)*: 6.

Il modello finale è stato quindi utilizzato per effettuare le predizioni sul test set e per calcolare le metriche di performance, oltre alla matrice di confusione. Il modello selezionato ha mostrato buone prestazioni complessive, ottenendo un'accuracy pari a circa **0.83** sul test set.

Le metriche evidenziano:

- Buona precision sulle classi principali, indicando predizioni generalmente affidabili;
- Recall inferiore rispetto alla Random Forest, soprattutto per le classi di rischio più elevato;
- F1-score che riflette un buon compromesso tra precision e recall, inferiore a quello ottenuto dall'approccio ensemble.

```
Accuracy: 0.8315015845189131
              precision    recall  f1-score   support

           0       0.91      0.93      0.92      2647
           1       0.88      0.85      0.86      3789
           2       0.86      0.85      0.85      3689
           3       0.79      0.81      0.80      2156
           4       0.69      0.71      0.70      1203
           5       0.62      0.52      0.56       711
           6       0.70      0.85      0.77       636

    accuracy                           0.83     14831
   macro avg       0.78      0.79      0.78     14831
weighted avg       0.83      0.83      0.83     14831
```

Figure 16: Metriche di performance - SVM

L'analisi dei risultati mostra che la SVM riesce a modellare efficacemente i confini tra le classi principali, pur risultando meno flessibile nel catturare le complessità più sottili presenti nei dati rispetto all'approccio ensemble. Anche in questo caso, gli errori di classificazione tendono a concentrarsi tra classi di rischio contigue, caratterizzate da confini meno netti nello spazio delle feature.

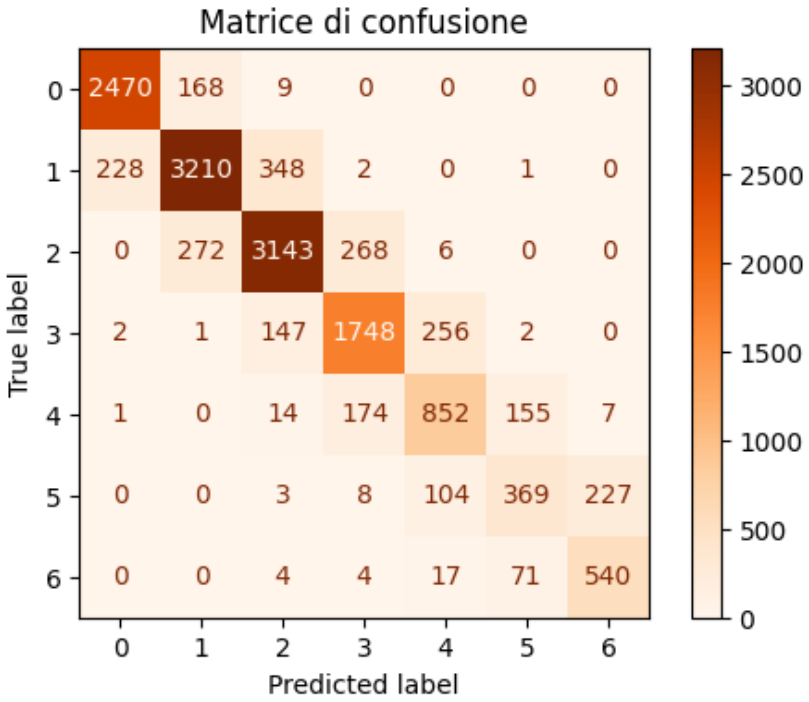

Figure 17: Matrice di confusione - SVM

3.2 Tecniche di ML supervised basate su reti neurali e architettura Feed-Forward

Il dataset è stato suddiviso nella fase di preprocessing in tre sottoinsiemi distinti: training, validation e test, ciascuno caratterizzato da 38 feature numeriche. Nella fase di modellazione vengono caricati e utilizzati i set precedentemente salvati.

Prima dell'addestramento, tutte le feature sono state normalizzate tramite Standard Scaling al fine di ridurre la disparità di scala tra le feature e rendere il processo di ottimizzazione più stabile ed efficiente.

Per la predizione del rischio di credito è stata adottata una rete neurale feed-forward completamente connessa, scelta appropriata per dati tabellari strutturati.

L'architettura è composta da:

- un layer di input con 38 neuroni, pari al numero di feature;
- tre hidden-layer, progettati per favorire una crescente astrazione delle informazioni, con una riduzione progressiva della dimensionalità nei layer successivi al primo;

- un layer di output con 7 neuroni, corrispondenti alle classi di rischio.

Ogni hidden-layer è seguito da:

- Batch Normalization, per ridurre l'Internal Covariate Shift e accelerare la convergenza;
- funzione di attivazione ReLU, scelta per la sua semplicità computazionale e per la capacità di mitigare il problema del vanishing gradient;
- Dropout, utilizzato come tecnica di regolarizzazione per ridurre l'overfitting.

Il modello è stato addestrato utilizzando la Cross-Entropy Loss, funzione standard per problemi di classificazione multiclasse. Come ottimizzatore è stato scelto Adam, efficace in contesti con dati rumorosi e superfici di loss complesse.

Al fine di migliorare la stabilità del processo di apprendimento e favorire una convergenza più efficace, è stato introdotto un learning rate scheduler di tipo StepLR, che riduce il learning rate di un fattore γ a intervalli regolari (ogni 20 epoche). Questa strategia consente di effettuare aggiornamenti dei pesi più ampi nelle fasi iniziali dell'addestramento, favorendo una rapida esplorazione dello spazio delle soluzioni, e aggiornamenti progressivamente più contenuti nelle fasi successive, permettendo un raffinamento della soluzione finale. Per mitigare il rischio di overfitting, è stata inoltre implementata una strategia di early stopping basata sull'andamento della loss di validazione, con una patience fissata a 10 epoche. Il modello associato alla migliore accuracy viene automaticamente salvato, garantendo la selezione della configurazione con la migliore capacità di generalizzazione.

La selezione degli iperparametri è stata effettuata tramite Random Search, esplorando combinazioni casuali di:

- learning rate,
- dimensione dei layer nascosti,
- probabilità di dropout,
- batch size,
- weight decay.

Questa strategia è risultata più efficiente rispetto a una grid search esaustiva, consentendo di individuare configurazioni performanti con un numero limitato di iterazioni. La combinazione migliore ha raggiunto un'accuratezza

di validazione pari a circa **0.896**, ottenuta con un hidden size di 64 neuroni, un learning rate pari a 0.001, un batch size di 256, un weight decay di 1×10^{-5} e una probabilità di dropout pari a 0.1.

```
--- Classifica migliori combinazioni ---
       lr  hidden_size  dropout  batch_size  weight_decay  best_val_acc
1  0.0010           64      0.1         256       0.00001      0.895954
3  0.0010           64      0.1          64       0.00001      0.893864
7  0.0005          128      0.2          64       0.00001      0.892043
8  0.0005           64      0.1         128       0.00001      0.889616
9  0.0005          128      0.2          64       0.00000      0.889144
5  0.0001          256      0.2          64       0.00010      0.878624
6  0.0001          128      0.1          64       0.00000      0.873432
4  0.0001          256      0.1         256       0.00001      0.871881
2  0.0001          256      0.1         256       0.00010      0.869117
0  0.0001           64      0.1         256       0.00010      0.842819
```

Figure 18: Classifica delle migliori combinazioni degli iperparametri tramite Random Search

```
FeedForward(
  (net): Sequential(
    (0): Linear(in_features=38, out_features=64, bias=True)
    (1): BatchNorm1d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (2): ReLU()
    (3): Dropout(p=0.2, inplace=False)
    (4): Linear(in_features=64, out_features=32, bias=True)
    (5): BatchNorm1d(32, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (6): ReLU()
    (7): Dropout(p=0.2, inplace=False)
    (8): Linear(in_features=32, out_features=16, bias=True)
    (9): BatchNorm1d(16, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (10): ReLU()
    (11): Dropout(p=0.2, inplace=False)
    (12): Linear(in_features=16, out_features=7, bias=True)
  )
)
```

Figure 19: Modello di rete neurale feed forward

Gli iperparametri ottimali sono risultati i seguenti:

- *learning rate*: 0.001
- *gamma*: 0.1
- *step size*: 20
- *batch size*: 128
- *hidden size*: 64
- *dropout prob*: 0.2canv

- *weight decay*: 0

Il modello selezionato ha mostrato buone prestazioni complessive, ottenendo un'accuracy pari a circa **0.893** sul test set. Le metriche di valutazione evidenziano quanto segue:

- **Recall**: elevato per le classi a basso e medio rischio, diminuisce per alcune classi ad alto rischio, in particolare per la classe 5, segnalando una maggiore difficoltà nel riconoscere tutti i casi più critici.
- **Precision**: mostra valori complessivamente elevati nelle classi più rappresentate.
- **F1-score**: riflette un buon compromesso tra precision e recall per la maggior parte delle classi, con valori più alti per le classi a basso rischio e una riduzione progressiva per le classi più difficili e meno rappresentate.

```
Accuracy: 0.893196682624233
              precision    recall  f1-score   support

           0       0.94      0.97      0.96      2647
           1       0.94      0.90      0.92      3789
           2       0.91      0.91      0.91      3689
           3       0.89      0.87      0.88      2156
           4       0.80      0.84      0.82      1203
           5       0.74      0.59      0.65       711
           6       0.71      0.90      0.79       636

    accuracy                           0.89     14831
   macro avg       0.85      0.86      0.85     14831
weighted avg       0.89      0.89      0.89     14831
```

Figure 20: Metriche di performance - FF

Il modello finale ha evidenziato una buona capacità di generalizzazione su dati non visti. L'early stopping ha interrotto l'addestramento all'epoca 56, indicando che oltre tale soglia il modello tendeva a non migliorare ulteriormente le prestazioni di validazione. Il risultato ottenuto conferma l'efficacia della rete feed-forward nel catturare le relazioni non lineari tra le caratteristiche del richiedente e il grado di rischio del prestito.

L'andamento della loss di training e di validazione, in funzione del numero di epoche di addestramento, mostra una rapida diminuzione iniziale, indice di un apprendimento efficace nelle prime fasi del training. A partire da circa

la 15ª–20ª epoca, la loss di training continua a decrescere in modo graduale, stabilizzandosi intorno a un valore di circa 0.56, mentre la loss di validazione si assesta su valori inferiori, intorno a 0.34. L'assenza di un aumento della loss di validazione, unitamente alla distanza relativamente stabile tra le due curve, suggerisce che il modello non manifesta fenomeni evidenti di overfitting. Il fatto che la loss di validazione risulti sistematicamente inferiore a quella di training è attribuibile alla presenza di tecniche di regolarizzazione attive esclusivamente in fase di training, in particolare il Dropout e la Batch Normalization. Durante l'addestramento, tali meccanismi introducono rumore e variabilità, rendendo il compito più complesso e aumentando la loss apparente sul training set; in fase di validazione, invece, il modello opera in modalità deterministica, producendo predizioni più stabili e una loss inferiore. L'analisi delle curve di training e validation loss evidenzia un processo di apprendimento stabile e ben regolarizzato.

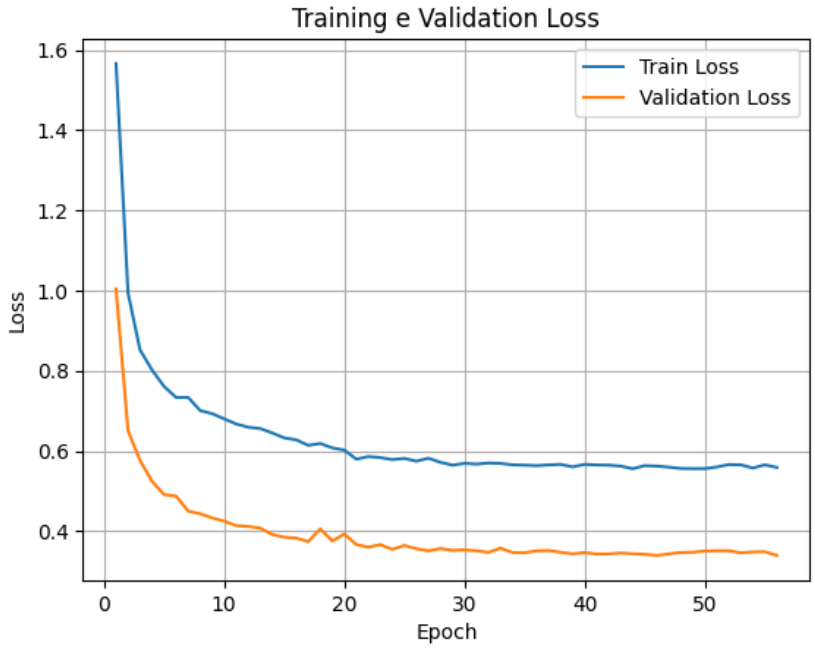

Figure 21: Training e Validation Loss - Grafico

Coerentemente all'andamento della loss, anche l'evoluzione dell'accuracy di training e di validazione nel corso delle epoche di addestramento mostra, in una fase iniziale, un incremento rapido dell'accuratezza (particolarmente marcato nelle prime 5–10 epoche, a testimonianza della capacità del modello di apprendere rapidamente le principali strutture informative presenti nei dati). Successivamente, l'accuratezza di training cresce in modo più graduale

fino a stabilizzarsi intorno a un valore di circa 0.78, mentre l'accuratezza di validazione raggiunge valori prossimi a 0.89, mantenendo un andamento stabile nelle epoche successive. L'analisi delle curve di accuracy conferma che la rete neurale feed-forward adottata è in grado di fornire predizioni affidabili e stabili del grado di rischio del prestito.

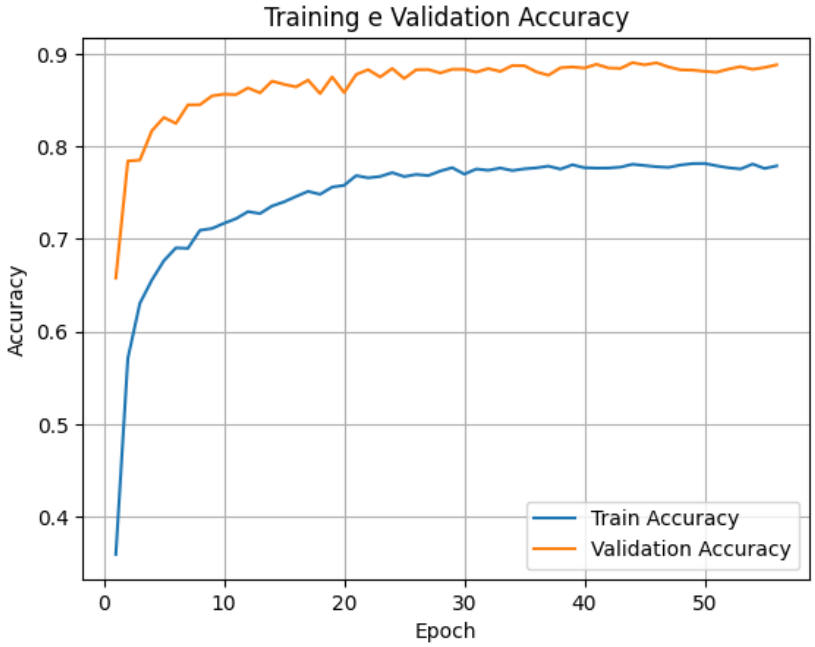

Figure 22: Training e Validation Accuracy - Grafico

La matrice di confusione ottenuta sul test set fornisce una rappresentazione dettagliata delle prestazioni del modello per ciascuna classe di rischio. La presenza di valori elevati lungo la diagonale principale indica che la maggior parte dei campioni viene classificata correttamente, confermando una buona capacità predittiva complessiva della rete neurale. Le classi di rischio più rappresentate nel dataset mostrano le migliori prestazioni, con un numero contenuto di errori di classificazione. Tali errori risultano prevalentemente localizzati tra classi adiacenti. Un comportamento analogo si osserva anche per le classi di rischio più elevate, per le quali il modello tende a confondere principalmente classi consecutive. È inoltre rilevante notare che il modello raramente commette errori di classificazione estremi, ossia assegnazioni a classi di rischio molto distanti da quella reale. Questo suggerisce che la rete neurale apprende efficacemente una struttura ordinata del rischio creditizio, pur mostrando una naturale incertezza nella separazione di categorie con confini meno definiti. Nel complesso, l'analisi della matrice di confusione

conferma la coerenza e l'affidabilità del modello, indicando che le principali fonti di errore sono riconducibili alla complessità del problema e allo sbilanciamento tra le classi, piuttosto che a limiti strutturali dell'architettura adottata.

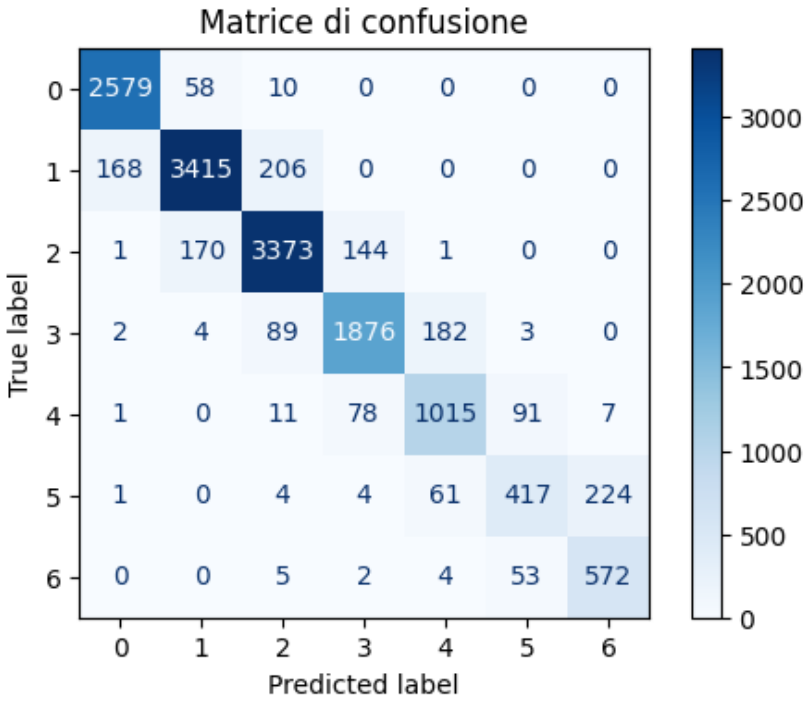

Figure 23: Matrice di confusione - Rete Neurale FF

3.3 Tecniche di ML supervised con modelli deep per Tabular Data

3.3.1 TabNet

È stato valutato un modello TabNet, una rete neurale progettata specificamente per dati tabulari, che utilizza un meccanismo di attenzione sequenziale per selezionare dinamicamente, a ogni passo decisionale, le feature più rilevanti per la predizione. Questo approccio consente al modello di apprendere relazioni non lineari complesse mantenendo al contempo un buon livello di interpretabilità, grazie alla possibilità di analizzare l'importanza delle feature utilizzate nei diversi step decisionali.

Data la natura eterogenea delle feature e la presenza di potenziali interazioni non lineari, non è stata applicata una riduzione dimensionale esplicita,

demandando al modello stesso la selezione delle informazioni più rilevanti attraverso le maschere di attenzione sparse.

La selezione degli iperparametri è stata effettuata mediante una procedura di Random Search, valutando diverse configurazioni su un numero limitato di trial, utilizzando un insieme di validazione separato. In particolare, sono stati esplorati i seguenti iperparametri:

- *n_d*: dimensione dello spazio latente per i blocchi decisionali, che controlla la capacità rappresentativa del modello;
- *n_a*: dimensione dello spazio di attenzione, impostata uguale a *n_d* per garantire un bilanciamento tra capacità e stabilità;
- *n_steps*: numero di passi decisionali sequenziali, che influenza la profondità del processo di selezione delle feature;
- *gamma*: parametro che regola il grado di riutilizzo delle feature tra i vari step;
- *lambda_sparse*: coefficiente di regolarizzazione che incoraggia la sparsità delle maschere di attenzione.

Diverse combinazioni di tali parametri sono state valutate selezionando la configurazione che massimizzava l'accuracy sul validation set, applicando inoltre una strategia di *early stopping* per ridurre il rischio di overfitting.

I migliori iperparametri ottenuti sono stati:

- *n_d* = *n_a*: 32;
- *n_steps*: 3;
- *gamma*: 1.3;
- *lambda_sparse*: 10^{-2};
- *mask_type*: entmax.

Il modello finale è stato utilizzato per effettuare le predizioni sul test set e per il calcolo delle metriche di performance, oltre alla matrice di confusione. TabNet ha mostrato buone prestazioni complessive, ottenendo un'accuracy sul test set pari a circa **0.92**.

Le metriche mostrano:

- Precision: valori elevati per le classi di rischio basso e medio, una riduzione della precision si osserva per le classi di rischio più elevato.

- Recall: elevato per le classi di rischio basso e medio, a conferma della capacità del modello di identificare correttamente la maggior parte dei campioni appartenenti a tali classi; il recall diminuisce per le classi ad alto rischio.
- F1-score: conferma il trend. Complessivamente alto e ben bilanciato per le classi principali, mentre si riduce per le classi di rischio più elevato.

```
Test accuracy finale: 0.9177398691929067
              precision    recall  f1-score   support

           0       0.95      0.97      0.96      2647
           1       0.95      0.92      0.93      3789
           2       0.93      0.94      0.93      3689
           3       0.93      0.92      0.92      2156
           4       0.89      0.88      0.88      1203
           5       0.78      0.69      0.73       711
           6       0.75      0.86      0.80       636

    accuracy                           0.92     14831
   macro avg       0.88      0.88      0.88     14831
weighted avg       0.92      0.92      0.92     14831
```

Figure 24: Metriche di performance - TabNet

TabNet ha dimostrato un'ottima capacità di bilanciare prestazioni e interpretabilità, elemento cruciale in un contesto di analisi del rischio, dove è fondamentale comprendere il contributo delle singole variabili alla decisione finale.

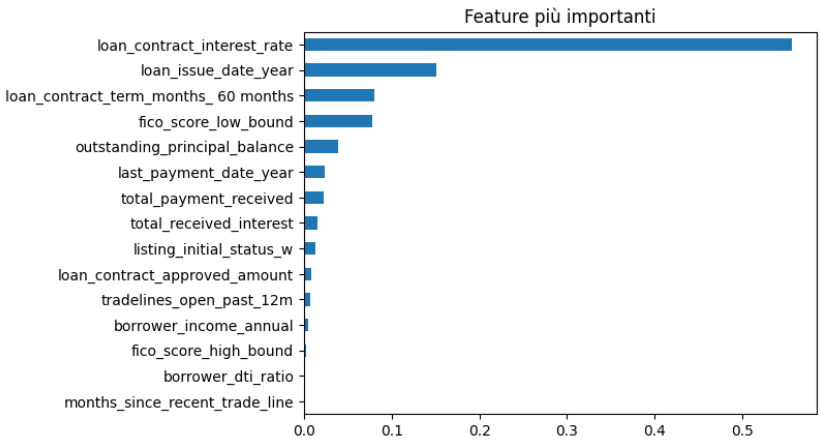

Figure 25: Feature più importanti individuate dal modello - TabNet

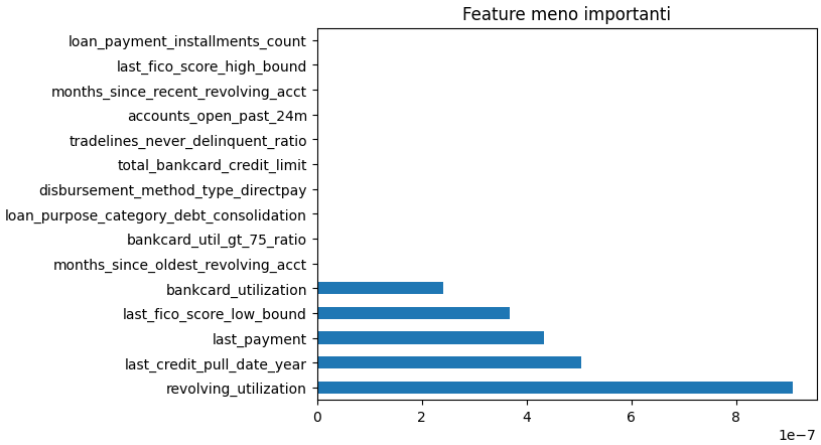

Figure 26: Feature meno importanti individuate dal modello - TabNet

L'analisi della matrice di confusione mostra che gli errori di classificazione sono quasi esclusivamente concentrati tra classi di rischio contigue, mentre risultano assenti o trascurabili confusioni tra classi lontane. Questo suggerisce che TabNet riesce a ordinare correttamente il rischio, pur incontrando difficoltà nel definire confini netti tra livelli adiacenti. La matrice di confusione conferma che TabNet è efficace nel modellare la struttura globale del rischio, mentre le principali fonti di errore, come negli altri modelli, sono attribuibili alla natura graduale e continua del fenomeno analizzato, più che a errori grossolani di classificazione.

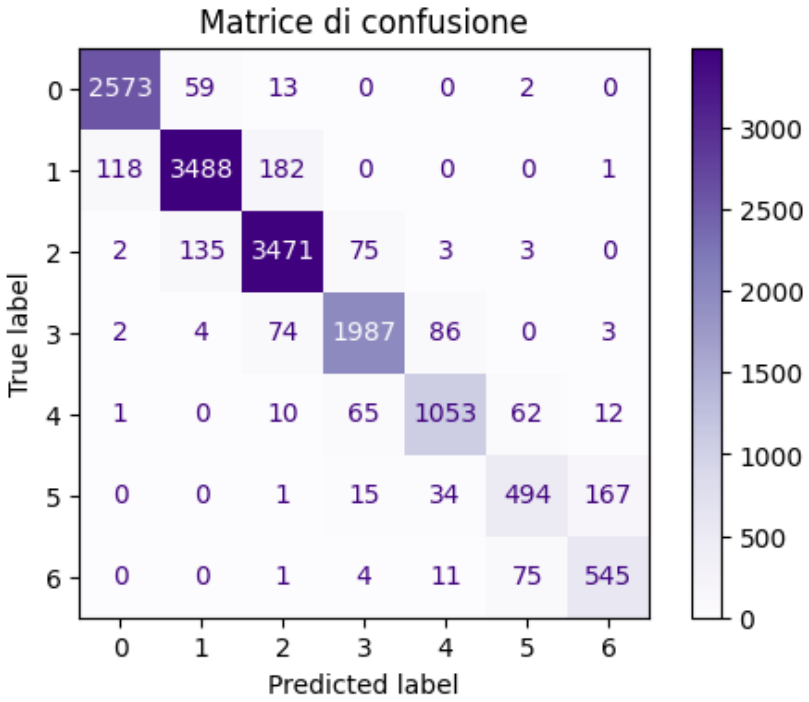

Figure 27: Matrice di confusione - TabNet

3.3.2 TabTransformer

È stato infine valutato un modello TabTransformer, basato su architetture Transformer adattate ai dati tabulari, che sfrutta meccanismi di self-attention per apprendere rappresentazioni contestualizzate delle feature, in particolare di quelle categoriali. Questo approccio consente di catturare interazioni globali tra le variabili, risultando particolarmente efficace in presenza di dipendenze complesse tra attributi.

A differenza di approcci più tradizionali, il TabTransformer non richiede una riduzione dimensionale preventiva, in quanto la trasformazione delle feature categoriali in embedding e l'attenzione multi-head permettono al modello di apprendere automaticamente rappresentazioni informative nello spazio latente.

La selezione degli iperparametri è stata effettuata tramite una ricerca mirata su un insieme ristretto di configurazioni, valutate sul validation set. In particolare, sono stati considerati i seguenti iperparametri:

- *dim*: dimensione degli embedding delle feature;
- *depth*: numero di blocchi di attenzione, che determina la profondità del

modello;

- *heads*: numero di teste di attenzione multi-head;
- *attn_dropout*: dropout applicato ai pesi di attenzione;
- *ff_dropout*: dropout applicato ai layer feed-forward.

La configurazione che ha ottenuto le migliori prestazioni in validazione è stata selezionata per l'addestramento finale.

I migliori iperparametri ottenuti sono stati:

- *dim*: 32;
- *depth*: 6;
- *heads*: 8;
- *attn_dropout*: 0.1;
- *ff_dropout*: 0.1.

Il modello è stato addestrato utilizzando una strategia di early stopping. L'addestramento è stato eseguito su CPU, scelta dettata da vincoli di compatibilità dell'ambiente di esecuzione.

Il modello finale è stato quindi valutato sul test set, calcolando le metriche di performance e la matrice di confusione. TabTransformer ha ottenuto un'accuracy sul test set pari a circa **0.83**, mostrando buone capacità di generalizzazione.

Le metriche mostrano:

- Precision: valori elevati per le classi più frequenti, si osserva una riduzione della precision per le classi meno rappresentate.
- Recall: elevato per le classi più comuni, il recall diminuisce per le classi meno frequenti.
- F1-score: complessivamente alto e bilanciato per le classi principali, mentre si riduce per le classi meno rappresentate, confermando i risultati delle altre metriche.

Nel complesso, il TabTransformer risulta efficace nel catturare dipendenze globali tra variabili, sebbene richieda un maggiore costo computazionale rispetto a modelli più semplici.

```
Test accuracy finale: 0.8311644528352775
              precision    recall  f1-score   support

           0       0.91      0.97      0.94      2647
           1       0.91      0.85      0.88      3789
           2       0.88      0.83      0.85      3689
           3       0.77      0.81      0.79      2156
           4       0.67      0.66      0.66      1203
           5       0.54      0.51      0.53       711
           6       0.69      0.85      0.76       636

    accuracy                           0.83     14831
   macro avg       0.77      0.78      0.77     14831
weighted avg       0.83      0.83      0.83     14831
```

Figure 28: Metriche di performance - TabTransformer

L'analisi della matrice di confusione conferma che il modello tende a confondere principalmente classi adiacenti, riflettendo la natura continua del rischio e la difficoltà intrinseca nel separare nettamente livelli contigui.

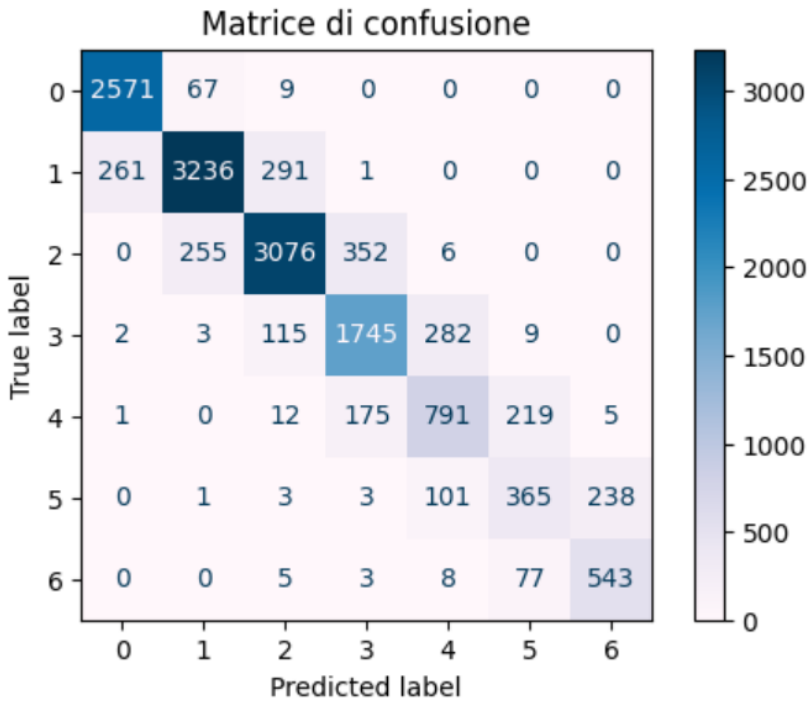

Figure 29: Matrice di confusione - TabTransformer

4 Conclusioni

In questo progetto è stato affrontato il problema della predizione del rischio creditizio come task di classificazione supervisionata multiclasse ordinata, seguendo una pipeline completa di Data Analytics che ha incluso analisi esplorativa, preprocessing avanzato, modellazione e valutazione delle prestazioni. L'ampiezza e l'eterogeneità del dataset, unite alla presenza di forte sbilanciamento delle classi e di distribuzioni fortemente asimmetriche, hanno reso il problema particolarmente sfidante e hanno evidenziato l'importanza di scelte metodologiche accurate nelle fasi preliminari.

Il confronto tra i modelli di Machine Learning tradizionali ha mostrato come approcci relativamente semplici possano ottenere risultati competitivi se supportati da un preprocessing robusto. In particolare, la Random Forest si è dimostrata il modello non deep più efficace, raggiungendo un'accuracy elevata e prestazioni bilanciate su tutte le classi di rischio. La sua capacità di modellare relazioni non lineari e interazioni complesse tra le feature risulta cruciale in un contesto come quello creditizio. Al contrario, KNN e SVM, pur ottenendo risultati soddisfacenti, hanno evidenziato limiti nella sepa-

razione delle classi di rischio più elevate, mostrando una maggiore sensibilità alla struttura locale dei dati e una minore flessibilità rispetto all'approccio ensemble.

L'introduzione di modelli basati su reti neurali ha permesso di analizzare il problema da una prospettiva più espressiva. La rete neurale feed-forward ha raggiunto prestazioni comparabili a quelle della Random Forest, dimostrando una buona capacità di generalizzazione e una gestione efficace delle non linearità, pur richiedendo una maggiore attenzione nella fase di tuning e un costo computazionale superiore.

I modelli deep progettati specificamente per dati tabulari hanno ulteriormente migliorato le prestazioni complessive. TabNet è risultato il modello migliore in termini di accuracy sul test set, mostrando un'ottima capacità di apprendere una struttura ordinata del rischio e di limitare gli errori di classificazione a classi contigue. Un ulteriore punto di forza di TabNet è rappresentato dall'interpretabilità, aspetto particolarmente rilevante in applicazioni reali di credit risk, dove la trasparenza delle decisioni è spesso un requisito fondamentale. Il TabTransformer, pur introducendo un approccio più sofisticato basato su self-attention, ha ottenuto prestazioni inferiori rispetto a TabNet e alla Random Forest, probabilmente a causa della complessità del modello e dei vincoli computazionali che ne hanno limitato l'ottimizzazione.

Nel complesso, i risultati evidenziano come l'aumento della complessità del modello non garantisca automaticamente un miglioramento delle prestazioni: modelli ensemble ben calibrati e reti neurali feed-forward risultano ancora estremamente competitivi su dati tabulari. Tuttavia, modelli come TabNet dimostrano che architetture deep specializzate possono offrire un vantaggio sia in termini di performance sia di interpretabilità. Le principali fonti di errore rimangono concentrate nella distinzione tra classi di rischio adiacenti, riflettendo la natura intrinsecamente continua e graduale del rischio creditizio.